

Лабораторна №4

Тема: Імплементация моделі генерації мовлення на основі мовної моделі

Корець Христина
Сампара Софія
Попенюк Софія

1. Опис використаної архітектури

В основі розробленого рішення лежить авторегресивна архітектура, що використовує текстову мовну модель для синтезу аудіо за підходом, натхненним TortoiseTTS та VALL-E.

Представлення аудіоданих: Сирий звуковий сигнал перетворюється на послідовність дискретних токенів (розмір словника - 8192 класи) за допомогою попередньо натренованого нейромережевого аудіокодека *FocalCodec*.

Базова модель: Як ядро генерації використано архітектуру *GPT-2* (із бібліотеки *transformers*). До неї інтегровано кастомні шари: *audio_emb* для створення ембедінгів аудіо-токенів та *audio_head* для фінальної класифікації токенів.

Форматування вхідних даних: Текстові та звукові токени об'єднуються в єдиний тензор за структурою: [Текст] -> [BOS] -> [Аудіо] -> [EOS]. Текст обробляється стандартним шаром ембедінгів GPT-2, а звукові та спеціальні токени - через *audio_emb*.

Обчислення функції втрат: У методі *forward* реалізовано механізм causal shift. Під час навчання модель передбачає виключно аудіо-токени та токен EOS. Текстові токени та токени вирівнювання (PAD) ігноруються під час розрахунку Cross-Entropy Loss шляхом встановлення міток у значення -100.

2. Опис методу навчання


Для забезпечення стабільного, масштабованого та відтворюваного процесу навчання було розроблено пайплайн на базі фреймворку **PyTorch Lightning**.

Тренувальний цикл: Створено клас *TTSLightningModule*, який інкапсулює логіку тренувального та валідаційного кроків.

Оптимізація: Навчання проводиться за допомогою оптимізатора AdamW (learning rate = $3e-4$, weight decay = 0.01). Для динамічного регулювання кроку навчання застосовано CosineAnnealingLR.

Інфраструктурні рішення:

- Використано обчислення зі змішаною точністю (16-mixed precision), що суттєво зменшило споживання відеопам'яті (VRAM) та прискорило процес оптимізації.
- Для моніторингу функції втрат у реальному часі налаштовано TensorBoardLogger.
- Реалізовано механізм автоматичного збереження checkpoints за допомогою ModelCheckpoint. Завдяки збереженню файлу *last.ckpt* було забезпечено можливість переривчастого естафетного навчання, що дозволило обійти ліміти GPU-середовищ.



3. Опис використаних підходів семплування

Інференс моделі реалізовано як **авторегресивний цикл генерації аудіо-токенів**. На кожному кроці модель отримує текстовий контекст і вже згенеровані аудіо-токени, після чого передбачає наступний аудіо-token. Для оптимізації обчислень використано **KV Cache (past_key_values)**: модель не перераховує увагу для всього попереднього контексту на кожному кроці, а повторно використовує збережені ключі та значення з попередніх кроків генерації.

Було протестовано чотири стратегії семплування:

Greedy Search - На кожному кроці обирається token з найбільшою ймовірністю. Метод є детермінованим і стабільним, але може давати менш природне або одноманітне звучання.

Top-K Sampling, k=50 - Модель обирає наступний token лише серед 50 найімовірніших tokenів. Це зменшує ризик вибору випадкових поганих tokenів, але додає різноманітність порівняно з greedy.

Top-P Sampling, p=0.90 - Модель обирає токен із найменшої множини токенів, сумарна ймовірність яких становить 90%. Це робить кількість кандидатів динамічною залежно від розподілу ймовірностей.

Top-K + Top-P - Комбінований підхід: спочатку залишаються top-k кандидати, після чого застосовується top-p фільтрація. Ідея полягає в тому, щоб одночасно обмежити випадковість і зберегти природну варіативність.

Також використовувалось **temperature scaling**. Температура керує “гостротою” розподілу ймовірностей: нижча температура робить генерацію більш передбачуваною, вища — більш випадковою. Для greedy температура фактично дорівнює 0, бо модель завжди бере найімовірніший токен. Для sampling-підходів використовувалась температура $T = 0.8$.

4. Таблиці метрик порівняння підходів семплування

Для оцінки якості синтезованого мовлення були використані три метрики:

Метрика	Що вимірює	Кращий напрям
CER	Наскільки текст, розпізнаний із згенерованого аудіо, збігається з оригінальним текстом	Нижче — краще
UTMOS	Автоматична оцінка природності та якості звучання	Вище — краще
SECS	Косинусна подібність між speaker embedding оригінального та згенерованого аудіо	Вище — краще

За отриманими результатами, Top-K Sampling показав найкращий баланс: він має найнижчий CER і найвищий UTMOS серед протестованих підходів. Greedy Search, своєю чергою, показав найкращий SECS, тобто найкраще зберігав характеристики голосу. Дані взяті з отриманої таблиці експериментів для fine-tuned та unfinetuned моделей.

	sample_id	strategy	reference_text	asr_text	n_tokens	duration_sec	CER	UTMOS	SECS
0	LJ048-0043	greedy	nor was there any requirement to report the na...	we know air inna and formatition report in mis...	236	9.44	0.793893	3.944280	0.530905
1	LJ048-0043	top_k_50	nor was there any requirement to report the na...	where i was the hematine erectione as steam of...	186	7.44	0.664122	4.152415	0.366205
2	LJ048-0043	top_p_090	nor was there any requirement to report the na...	whether it were pierre in our duration appuite...	210	8.40	0.763359	4.250118	0.570583
3	LJ048-0043	top_k_50_top_p_090	nor was there any requirement to report the na...	or he was not a rackety no cords of the receas...	243	9.72	0.717557	3.876025	0.536062

Порівняння з unfinetuned моделлю

	model	sample_id	strategy	reference_text	asr_text	n_tokens	duration_sec	CER	UTMOS	SECS
0	unfinetuned	LJ048-0043	greedy	nor was there any requirement to report the na...	360d2 360d2 360d4	400	16.0	0.969466	2.060339	0.012245
1	unfinetuned	LJ048-0043	top_k_50	nor was there any requirement to report the na...	why paint is 문z and fix a hate me of encouragi...	400	16.0	1.213740	1.671280	-0.031493
2	unfinetuned	LJ048-0043	top_p_090	nor was there any requirement to report the na...	thats about to do i think that they cant move ...	400	16.0	0.801527	1.552069	0.033299
3	unfinetuned	LJ048-0043	top_k_50_top_p_090	nor was there any requirement to report the na...	pressure pressure terrajan dot gang	400	16.0	0.809160	1.703867	-0.040726

Fine-tuned модель значно краща за unfinetuned baseline за всіма основними метриками. Unfinetuned модель завжди генерує 400 токенів, тобто доходить до максимального обмеження max_new_tokens. Це означає, що вона не навчилась передбачати EOS-токен і не знає, коли потрібно завершувати аудіо.

	model	strategy	CER	UTMOS	SECS	duration_sec	n_tokens
0	finetuned	greedy	0.668170	4.196067	0.526590	7.712	192.8
4	unfinetuned	greedy	0.912139	1.705114	-0.050399	16.000	400.0
1	finetuned	top_k_50	0.662726	4.309353	0.501894	7.352	183.8
5	unfinetuned	top_k_50	1.419400	1.905995	-0.030347	16.000	400.0
2	finetuned	top_k_50_top_p_090	0.680712	4.069636	0.452735	7.576	189.4
6	unfinetuned	top_k_50_top_p_090	1.635161	1.727800	-0.019152	16.000	400.0
3	finetuned	top_p_090	0.677650	4.258085	0.460292	7.424	185.6
7	unfinetuned	top_p_090	1.622664	1.746297	0.002876	16.000	400.0

5. Гіпотези й думки щодо отриманих результатів

- *Fine-tuned* модель демонструє суттєво кращу якість порівняно з *unfinetuned baseline*. Середній UTMOS для *fine-tuned* моделі перебуває приблизно в діапазоні 4.07–4.31, тоді як для *unfinetuned* моделі — лише 1.70–1.91. Це означає, що після донавчання модель навчилась генерувати аудіо-токени, які декодуються у відносно природне мовлення. Водночас *unfinetuned* модель має випадково ініціалізовані аудіо-шари, тому її вихід більше схожий на шум або нестабільне мовлення, ніж на якісний синтезований голос.
- Найкращий результат серед *sampling*-підходів для *fine-tuned* моделі показав **Top-K Sampling, $k=50$** . Він має найнижчий CER (0.663) і найвищий UTMOS (4.309). Ймовірно, *Top-K* добре обмежує простір вибору наступного токена: модель не може вибрати дуже малоімовірні аудіо-токени, але все ще має достатньо варіативності для природнішого звучання. *Greedy Search* має трохи гірший CER та UTMOS, але найкращий SECS. Це може означати, що *greedy*-декодування краще зберігає найбільш типову манеру мовлення, але звучить менш гнучко або менш природно.
- *Top-P Sampling* і комбінація *Top-K* + *Top-P* не дали кращих результатів у цьому експерименті. Ймовірно, для цієї моделі розподіл ймовірностей аудіо-токенів ще недостатньо добре відкалібрований, тому *nucleus sampling* може іноді пропускати токени, які погіршують текстову відповідність або стабільність звучання. Особливо це видно на *unfinetuned* моделі: *stochastic sampling* різко погіршує CER, бо модель фактично семплює випадкові аудіо-токени з непідготовленого розподілу.
- Також можна припустити, що модель має проблему з “бормотанням” або втратою змісту на довших текстах. Це видно з високого CER: навіть коли UTMOS високий, тобто аудіо звучить природно, розпізнаний *Whisper* текст часто не збігається з оригінальним. Отже, модель уже навчилась генерувати мовоподібний сигнал, але ще недостатньо добре контролює точну відповідність між вхідним текстом і згенерованим мовленням. Це типова проблема для слабко або недовго навчених TTS-моделей: акустична якість може з’явитися раніше, ніж стабільна текстова керованість.